ILPD Veri Seti ile Karaciğer Hastalığı Tespitinde Makine Öğrenmesi Yöntemlerinin Karşılaştırmalı ve Yanlılık Analizi

Berkay Aras, Emrullah Yıldız, Shima Delavar
Yazılım Mühendisliği Bölümü, İstanbul Topkapı Üniversitesi
FET340 Makine Öğrenmesi — Haziran 2026

ÖZ

Özet — Bu çalışmada, UCI Makine Öğrenmesi Deposu'ndan elde edilen Hindistan Karaciğer Hasta Veri Seti üzerinde bir makine öğrenmesi boru hattı önerilmektedir. Boru hattı; dört klinik motivasyonlu bileşik özellik üretimini, bilgi kazanımı tabanlı özellik seçimini, SMOTE tabanlı sınıf dengelemeyi, PCA(n=3) boyut indirgemeyi ve yedi sınıflandırıcı için tekdüzen GridSearchCV uygulamasını kapsamaktadır. Değerlendirilen sınıflandırıcılar şunlardır: Naive Bayes, K-En Yakın Komşusu, Karar Ağacı, Rastgele Orman, Lojistik Regresyon, Destek Vektör Makinesi (SVM) ve Yapay Sinir Ağı'dır. Rastgele Orman en yüksek performansı elde etmiştir: Test Doğruluğu=0.8205, F1=0.8757, ROC-AUC=0.8636, 5-Katlı CV F1=0.742±0.061. Dört aşamalı ablasyon çalışması, tam boru hattının ham veriye kıyasla ortalama F1'de +1.42 puanlık iyileşme sağladığını göstermektedir. Cinsiyet yanlılığı analizi, Rastgele Orman modelinin kadın hastalarda erkeklere kıyasla anlamlı biçimde daha yüksek yanlış negatif oranı sergilediğini ortaya koymaktadır. Bu bulgu, SMOTE tabanlı sınıf dengelemenin demografik yanlılığı tam olarak gideremediğine işaret etmektedir.

Anahtar Kelimeler — karaciğer hastalığı tespiti; makine öğrenmesi, ILPD; Feature Engineering, bilgi kazanımı; PCA, SMOTE; GridSearchCV, cinsiyet yanlılığı; sağlıkta adalet

I. GİRİŞ

Karaciğer hastalıkları dünya genelinde önemli bir halk sağlığı sorunu olmayı sürdürmektedir. Dünya Sağlık Örgütü raporlarına göre siroz ve kronik karaciğer hastalıkları her yıl yaklaşık iki milyon ölüme yol açmakta; bu yük özellikle Güney ve Güneydoğu Asya'da daha ağır hissedilmektedir [1]. Klinik tanı, bilirubin, aminotransferaz (ALT, AST) ve serum proteinleri gibi birden fazla biyobelirtecin birlikte yorumlanmasını gerektirdiğinden, deneyimli uzmanlar için bile zaman alan ve hataya açık bir süreçtir.

Makine öğrenmesi yöntemleri bu noktada umut verici bir alternatif sunmaktadır: biyobelirteç örüntülerini otomatik olarak çözümleyerek klinisyenlere karar destek aracı olabilirler. UCI Makine Öğrenmesi Deposu'ndaki ILPD veri seti [2], bu alanda en sık başvurulan ölçüt kaynaklardan biridir; ancak sınıf dengesizliği ve özellikler arası yüksek korelasyon metodolojik dikkat gerektirmektedir.

Literatürde üç temel boşluk göze çarpmaktadır. İlk olarak hiperparametre optimizasyonu çoğunlukla yalnızca belirli sınıflandırıcılara uygulanmakta, bu da modeller arası karşılaştırmaları güvenilmez kılmaktadır. İkincisi, boyut indirgeme yöntemleri metodolojik boru hattı adımı olarak değil keşifsel araç olarak ele alınmaktadır. Üçüncüsü, cinsiyet bazlı YNO farklılıkları klinik önemine karşın nadiren raporlanmaktadır.

Bu çalışma söz konusu boşlukları beş özgün katkıyla gidermektedir: (1) klinik literatürden esinlenen dört bileşik biyobelirteç özelliğinin üretimi; (2) PCA (n=3)'ün boru hattının zorunlu bir adımı olarak entegrasyonu; (3) yedi sınıflandırıcının tamamına tekdüzen GridSearchCV uygulanması; (4) her ön-işleme adımının F1 katkısını ölçen ablasyon çalışması; (5) SMOTE uygulanmış bir boru hattında dahi kadın hastalarda erkeklere göre daha yüksek YNO gözlemlendiğinin gösterilmesi.

II. LİTERATÜR TARAMASI

Tablo I, ILPD üzerindeki başlıca önceki çalışmaları bu araştırmayla karşılaştırmalı biçimde özetlemektedir. Ramana ve arkadaşları [3], beş sınıflandırıcıyı değerlendirerek Rastgele Orman'ın %77,97 doğrulukla en iyi sonucu verdiğini ortaya koymuştur. Abdar ve arkadaşları [4] AdaBoost ile %80,64 doğruluğa ulaşarak topluluk öğreniminin üstünlüğünü göstermiştir.

Straw ve Wu [5], ILPD literatürüne demografik adalet boyutunu kazandırmıştır. Çalışmalarında incelenen tüm sınıflandırıcılarda kadın hastalarda sistematik biçimde daha yüksek YNO gözlemlenmiştir; bizim bulgularımız da bu sonuçları desteklemektedir. Ganji ve arkadaşları [6], dört aşamalı bir boru hattıyla LGBM modelini %82,12 doğruluğa optimize etmiştir. Ali ve arkadaşları [7] ise SMOTE-ENN hibrit dengelemeyle %93.20 doğruluğa ulaşmıştır.

Mevcut çalışmanın temel farkı şudur: yedi modelin tamamına tekdüzen GridSearchCV uygulanmış, PCA boru hattının ayrılmaz bir parçası olarak tasarlanmış ve cinsiyet adaleti birincil araştırma sorusu olarak ele alınmıştır.

TABLO I. ILPD LITERATÜR ÖZETI

Yazar (Yıl)	Yöntem	En İyi	Doğ.%	F1%
Ramana vd. (2011) [3]	NB, DT, CART, DT, CART	R. Forest	77.97	—
Abdar vd. (2018) [4]	NB, SVM, DT, SVM, DT	AdaBoost	80.64	—
Straw & Wu (2022) [5]	LR, RF, SVM, NB+Cinsiyet	R. Forest	>70	—
Ganji vd. (2025) [6]	MLP, SVM, DT, LGBM, LR+IG	LGBM	82.12	—
Ali vd. (2025) [7]	SMOTE-ENN+Hibrit+RFE	Hibrit	93.20	—
Bu Çalışma (2026)	ÖM+BK+PCA+GS — 7 Model	R. Forest	82.05	87.57

III. VERİ SETİ

ILPD [2], Hindistan'ın Andhra Pradesh bölgesindeki hastalardan 2012 yılında derlenmiş ve UCI ML Deposu aracılığıyla kamuya açık hâle getirilmiştir. Veri kümesi 583 örnek içermekte olup bunların 416'sı karaciğer hastası, 167'si sağlıklı bireydir. Cinsiyet dağılımında 441 erkek ve 142 kadın bulunmakta; bu asimetri cinsiyet yanlılığı analizini metodolojik açıdan zorunlu kılmaktadır.

Giriş özellikleri şunlardır: Yaş, Cinsiyet, Toplam Bilirubin, Direkt Bilirubin, Alkalen Fosfataz, ALT, AST, Toplam Proteinler, Albumin ve Albumin-Globulin Oranı. IQR tabanlı uç değer analizi, Toplam Bilirubin' de %14.41, ALT' de %12,52 ve AST 'de %11,32 aykırı değer bulunduğunu ortaya koymuştur. Albumin-Globulin Oranı sütunundaki dört eksik değer medyan ile doldurulmuştur.

IV. METODOLOJİ

Önerilen boru hattı dokuz ardışık adımdan oluşmaktadır: (1) Medyan impütasyon, (2) Özellik Mühendisliği, (3) BK özellik seçimi, (4) Tabakalandırılmış eğitim/test bölünmesi (%80/%20), (5) SMOTE (yalnızca eğitim), (6) StandardScaler, (7) PCA(n=3), (8) GridSearchCV (cv=5, metrik=F1), (9) Değerlendirme.

A. Özellik Mühendisliği

Klinik literatürden esinlenerek dört bileşik özellik üretilmiştir. Bili Oranı = Direkt Bili / (Toplam Bili + ε), hepatoselüler ve obstrüktif karaciğer hastalıklarını ayırt etmeye yardımcı olur. Enzyme_Sum = ALT + AST, karaciğer hasarının göstergesi olan iki aminotransferazı tek değerde toplar. Enzyme_Oran = ALT / (AST + ε), alkolik ile alkolik olmayan karaciğer yağlanmasını birbirinden ayırt etmede kullanılan ALT/AST oranını temsil eder [8]. Protein_Albumin_Fark = Toplam Proteinler − Albumin, kronik inflamasyonda yükselen globulin fraksiyonunu ölçer.

B. Bilgi Kazanımı ile Özellik Seçimi

Bilgi Kazanımı (BK), $BK(Y|X) = H(Y) - H(Y|X)$ formülüyle her özelliğin hedef değişkenin belirsizliğini ne ölçüde azalttığını ölçer. Sürekli özellikler bölümlere ayrılmıştır. 0.06 eşiğini aşan yedi özellik seçilmiştir: Toplam Bilirubin (0.0924), Direkt Bilirubin (0.0891), Enzyme_Sum (0.0878), AST (0.0750), Bili_Oranı (0.0717), ALT (0.0648) ve Alkalen Fosfataz (0.0609). Seçilen yedi özelliğin tamamında Mann-Whitney U testi anlamlı sınıf farklılıkları saptamıştır.

BK analizinin ardından Rastgele Orman'ın Gini safsızlığı azalması tabanlı özellik önemi de hesaplanmıştır. Bu ikinci analizde Alkalen Fosfataz birinci sıraya yükselmiş, bilirubin değişkenleri ise alt sıralarda yer almıştır. İki yöntemin farklı sıralamalar üretmesi, özellik öneminin algoritmaya ve değerlendirme ölçütüne göre değiştiğini göstermektedir.

C. SMOTE ile Sınıf Dengeleme

Veri sızıntısını önlemek amacıyla SMOTE [9] yalnızca eğitim kümesine uygulanmıştır. SMOTE'tan önce eğitim setinin Shannon entropisi 0.8627 bit iken işlem sonrasında 1.0000 bit'e yükselmiştir. SMOTE sonrası eğitim örnek sayısı 333'ten 666'ya çıkmıştır.

D. PCA ile Boyut İndirgeme

StandardScaler uygulamasının ardından PCA gerçekleştirilmiştir. Çöküş grafiği incelendiğinde, ilk üç bileşenin toplam varyansın %82,97'sini açıkladığı görülmektedir: BC1=%45,57, BC2=%24.39, BC3=%13.01. Dördüncü bileşen yalnızca %12,58 katkı sağladığından n=3 seçilmiştir. PCA yalnızca eğitim verisi üzerinde uyumlandırılmış hem eğitim hem de test verisine dönüşüm uygulanmıştır.

E. GridSearchCV ile Hiperparametre Optimizasyonu

Yedi sınıflandırıcının tamamına F1 metriği üzerinden beş katlı tabakalandırılmış çapraz doğrulama kullanan GridSearchCV uygulanmıştır. Bu yaklaşım, karşılaştırmanın gerçek algoritma farklılıklarından kaynaklanmasını güvence altına almaktadır. Rastgele Orman için arama uzayı özellikle genişletilmiştir: 240 parametre kombinasyonu × 5 katlı = 1200 uyum hesabı gerçekleştirilmiştir.

TABLO II. GRIDSEARCHCV EN İYI PARAMETRELER

Model	En İyi Parametreler
Naive Bayes	var_smoothing=1e-9
KNN	n_neighbors=9, weights=distance
Karar Ağacı	gini, max_depth=10, min_leaf=2
R. Orman	n_est=800, depth=15, bootstrap=True
Lojistik Reg.	C=1.0, l2, lbfgs, max_iter=500
DVM (SVM)	C=10, rbf, gamma=scale
YSA (MLP)	hidden=(128,64), tanh, α=1e-4

F. Cinsiyet Bazlı Yanlılık Analizi

Straw ve Wu'nun [5] metodolojisi benimsenerek en yüksek F1 skorunu elde eden Rastgele Orman modeli, erkek (n=90) ve kadın (n=27) test alt gruplarında ayrı ayrı değerlendirilmiştir. Birincil adalet ölçütü olarak YNO seçilmiştir; daha yüksek YNO daha fazla kaçırılan tanıya karşılık gelmektedir. Gruplar arası YNO farkının ≥0.05 olması klinik açıdan anlamlı kabul edilmiştir.

V. DENEYSEL BULGULAR

A. Model Karşılaştırması

Tablo III, yedi sınıflandırıcının F1 skoruna göre sıralı performansını sunmaktadır. Rastgele Orman; Test F1=0.8757, Doğruluk=0.8205 ve ROC-AUC=0.8636 ile açık ara en iyi performansı sergilemiştir. Karar Ağacı (F1=0.8354) ve KNN (F1=0.7947) ikinci ve üçüncü sıradadır.

Lojistik Regresyon ve DVM, kesinlik değerleri>0.97 olmasına karşın geri çağırma değerleri <0,60 düzeyinde kalmıştır; bu modeller PCA uzayında pozitif örneklerin büyük bölümünü sınıflandırmayı reddetmektedir. Naive Bayes en düşük F1 skorunu (0.6167) almış olmakla birlikte ROC-AUC değeri (0.8310) rekabet edebilir düzeyde kalmıştır.

TABLO III. TÜM MODELLERIN TEST SETI VE ÇAPRAZ DOĞRULAMA PERFORMANSI

Model	CV F1	Doğ.	Kes.	Duy.	F1	AUC
R. Orman	**0.742±0.061**	**0.8205**	**0.8605**	**0.8916**	**0.8757**	**0.864**
Karar Ağacı	0.710±0.057	0.7778	0.8800	0.7952	0.8354	0.757
KNN	0.743±0.056	0.7350	0.8824	0.7229	0.7947	0.814
YSA (MLP)	0.649±0.052	0.7350	0.9815	0.6386	0.7737	0.813
Lojistik Reg.	0.624±0.037	0.7009	0.9800	0.5904	0.7368	0.827
DVM (SVM)	0.611±0.049	0.6923	0.9796	0.5783	0.7273	0.833
Naive Bayes	0.504±0.037	0.6068	1.0000	0.4458	0.6167	0.831

B. Aşırı Uyum Analizi

KNN mükemmel eğitim doğruluğuna (1.000) ulaşmış ancak test setinde orta düzeyde performans göstermiştir. Karar Ağacı benzer bir eğilim sergilese de max_depth=10 kısıtlaması sayesinde test F1'de ikinci sıraya yerleşmiştir. YSA ve Lojistik Regresyon negatif Δ değeri göstermiştir; SMOTE ile genişletilmiş eğitim setinin test setinden daha zor olabileceğine işaret etmektedir. Rastgele Orman Δ=0.178 ile yönetilebilir aşırı uyum sergileyerek en yüksek test F1'ini elde etmektedir.

C. Ablasyon Çalışması

Tablo IV, dört kümülatif yapılandırma boyunca her ön-işleme adımının model performansına katkısını nicelleştirmektedir. Ham özelliklerle (A) yedi model ortalaması F1=0.7516 olmuştur. Özellik Mühendisliği eklemesi (B) bunu 0.7532'ye yükseltmiştir. BK seçimi tek başına (C) ortalamayı 0.7381'e düşürmüştür; bu durum, özellik sayısının 14'ten 7'ye indirilmesinin varsayılan parametrelerle daha az bilgi sunabileceğine işaret etmektedir. PCA ve GridSearchCV'nin eklenmesiyle (D) ortalama F1=0.7658 ile en yüksek değere ulaşılmış; bu iki adımın sinerjik katkısı açıkça görülmüştür.

TABLO IV. ABLASYON ÇALIŞMASI F1 SKORLARI

Model	A: Ham	B: +ÖM	C: +BK	D: +PCA+GS
Naive Bayes	0.656	0.667	0.634	0.617
KNN	0.740	0.730	0.780	0.795
Karar Ağacı	0.740	0.730	0.770	0.835
R. Orman	0.810	0.830	0.810	0.876
Lojistik Reg.	0.790	0.790	0.750	0.737
DVM (SVM)	0.750	0.770	0.720	0.727
YSA (MLP)	0.780	0.760	0.710	0.774
Ortalama	**0.752**	**0.753**	**0.738**	**0.766**

D. İstatistiksel Anlamlılık — Wilcoxon Testi

Rastgele Orman'ın diğer modellere kıyasla anlamlı üstünlük gösterip göstermediği, 5-katlı CV F1 skorları üzerinden Wilcoxon işaretli sıra testiyle araştırılmıştır. Tablo V sonuçları incelendiğinde hiçbir karşılaştırmanın istatistiksel anlamlılık eşiğine ulaşamadığı görülmektedir. Bu sonuç doğrudan n=5 gözlem sayısının küçüklüğünden kaynaklanmaktadır; Wilcoxon testiyle bu örneklem büyüklüğünde ulaşılabilecek en küçük p değeri 0.0625'tir. Bununla birlikte, test seti performansındaki mutlak farklar pratik anlamlılığını korumaktadır.

TABLO V. WILCOXON İŞARETLI SIRA TESTI

Karşılaştırma	W	p-değeri	Anlamlı?
RO vs Naive Bayes	0.0	0.0625	Hayır
RO vs KNN	6.0	0.8125	Hayır
RO vs Karar Ağacı	0.0	0.0625	Hayır
RO vs Lojistik	0.0	0.0625	Hayır
RO vs DVM (SVM)	0.0	0.0625	Hayır
RO vs YSA (MLP)	0.0	0.0625	Hayır

E. Cinsiyet Bazlı Yanlılık Analizi

En yüksek F1 skorunu elde eden Rastgele Orman modeli, test setinin erkek (n=90) ve kadın (n=27) alt gruplarında ayrı ayrı değerlendirilmiştir. Tablo VI'ya bakıldığında, erkek alt grubunda YNO=0.0781 elde edilirken kadın alt grubunda bu oranın YNO=0.2105'e yükseldiği görülmektedir. İki grup arasındaki fark Δ=+0.1324 olup klinik anlamlılık eşiği 0.05'i belirgin biçimde aşmaktadır. Bu sonuç SMOTE tabanlı sınıf dengeleme uygulanmış olmasına karşın devam etmektedir; erkek örneklerin eğitim dağılımına daha fazla katkısı modelin kadın hastaya özgü klinik örüntüleri eksik temsil etmesine yol açmaktadır.

TABLO VI. RASTGELE ORMAN — CINSIYET BAZLI PERFORMANS

Metrik	Erkek (n=90)	Kadın (n=27)	Fark (K−E)
Doğruluk	0.8222	0.8148	−0.0074
Kesinlik	0.8429	0.9375	+0.0946
Duyarlılık (TPR)	0.9219	0.7895	−0.1324
F1 Skoru	0.8806	0.8571	−0.0235
YNO (FNR)	**0.0781**	**0.2105**	**+0.1324**
Özgüllük (TNR)	0.5769	0.8750	+0.2981
YPO (FPR)	0.4231	0.1250	−0.2981

VI. TARTIŞMA

Bu çalışmanın en temel metodolojik özelliği, yedi sınıflandırıcının tamamına GridSearchCV'nin tekdüzen biçimde uygulanmasıdır. Literatürde yalnızca belirli modellere hiperparametre optimizasyonu yapılarak karşılaştırma yapılması yaygın bir hatadır; bu çalışma söz konusu sorunu ortadan kaldırmaktadır.

Ablasyon sonuçları birkaç açıdan dikkat çekicidir. BK seçiminin tek başına ortalama F1'i düşürmesi beklenmedik bir bulgudur. PCA ve GridSearchCV ile birleşince tablonun değişmesi, bu ön-işleme adımlarının sinerjik bir yapıda çalıştığını ortaya koymaktadır.

Cinsiyet yanlılığı bulguları, SMOTE tabanlı sınıf dengelemenin gruplar arası YNO farkını gideremediğini açıkça göstermektedir. Bunun temel nedeni demografik dengesizliktir: 441 erkek örneği tüm eğitim dağılımını şekillendirmekte, model kadın hastaya özgü klinik belirteçleri eksik temsil etmektedir. Otoimmun hepatit gibi kadına özgü karaciğer durumlarının mevcut özellik uzayında yetersiz kapsanması da bu duruma katkıda bulunuyor olabilir.

Wilcoxon testlerinde hiçbir karşılaştırmanın istatistiksel anlamlılık eşiğine ulaşamaması, yalnızca n=5 katlı gözlem sayısının küçüklüğünden kaynaklanmakta olup beklenen bir bulgudur. Sonuçların güçlendirilmesi için k≥10 katlı çapraz doğrulama önerilmektedir.

VII. GELECEK ÇALIŞMALAR

Dört öncelikli araştırma yönü önerilmektedir. İlk olarak cinsiyet bilinçli yeniden örnekleme teknikleri kadın alt grubundaki YNO'yu hedefli biçimde azaltabilir. İkinci olarak SHAP değerleri, hangi özelliklerin yanlılık farkını beslediğini belirleyerek hem klinik içgörü hem de özellik mühendisliğine yol gösterme işlevi görebilir. Üçüncü olarak mevcut çalışmada test setinde yalnızca 27 kadın bulunmaktadır; çok merkezli veri kümeleri istatistiksel gücü artıracaktır. Son olarak Δ-YNO minimizasyonu gibi adalet kısıtlı optimizasyon hedefleri GridSearchCV çerçevesine entegre edilebilir.

VIII. SONUÇ

Bu çalışmada ILPD üzerinde karaciğer hastalığı tespiti için sistematik ve tekrarlanabilir bir makine öğrenmesi boru hattı sunulmuştur. Rastgele Orman Test Doğruluğu=0.8205 ve F1=0.8757 ile en yüksek performansı sergilemiştir. Ablasyon çalışması, tam boru hattının ortalama F1'de +1,42 puan iyileşme sağladığını; bu kazanımın ağırlıklı olarak PCA ve GridSearchCV adımlarından geldiğini ortaya koymuştur.

Cinsiyet yanlılığı analizi, SMOTE uygulanmış bir boru hattında dahi kadın hastalarda anlamlı ölçüde daha yüksek YNO gözlemlendiğini ortaya koymuştur. Bu bulgu, demografik adaletin yalnızca sınıf düzeyi dengeleme yöntemleriyle tam olarak sağlanamayabileceğini vurgulamaktadır. Wilcoxon testleri 5-katlı sınırlaması nedeniyle istatistiksel anlamlılığa ulaşamamış olsa da test seti performansındaki mutlak farklılıkların pratik anlamlılığı sürmektedir.

TEŞEKKÜR

Yazarlar, ILPD veri setini kamuya açık hâle getiren UCI Makine Öğrenmesi Deposu'na ve cinsiyet adaleti çerçevesini literatüre kazandıran Straw & Wu (2022) çalışmasına teşekkür eder.

KAYNAKLAR

[1] World Health Organization, Noncommunicable Diseases: Progress Monitor 2022. Geneva: WHO, 2023.

[2] B. V. Ramana, "ILPD (Indian Liver Patient Dataset)," UCI Machine Learning Repository, 2012. [Çevrimiçi]. Erişilebilir: https://archive.ics.uci.edu/dataset/225. [Erişim: Haz. 2026].

[3] B. V. Ramana, M. S. P. Babu, ve N. B. Venkateswarlu, "A critical study of selected classification algorithms for liver disease diagnosis," Int. J. Database Manag. Syst., c. 3, sy. 2, ss. 101–114, May. 2011.

[4] M. Abdar, M. Zomorodi-Moghadam, X. Zhou, ve I.-H. Guan, "A comparison of data mining techniques for liver disease prediction," Procedia Comput. Sci., c. 127, ss. 252–261, 2018.

[5] I. Straw ve H. Wu, "Investigating for bias in healthcare algorithms: a sex-stratified analysis of supervised machine learning models in liver disease prediction," BMJ Health Care Inform., c. 29, sy. 1, e100457, 2022.

[6] A. Ganji, D. Usha, ve P. S. Rajakumar, "Enhancing early detection of liver disease using feature selection and machine learning," Scalable Comput.: Pract. Exp., c. 26, sy. 3, ss. 1104–1115, 2025.

[7] M. Ali, W. Iqbal, ve M. Hameed, "Improving liver disease diagnosis with hybrid SMOTE-ENN balanced machine learning models," Front. Med., c. 12, s. 1502749, 2025.

[8] A. K. Diehl, L. Fulton, ve R. L. Engel, "Aspartate aminotransferase to alanine aminotransferase ratio in patients without alcoholism," Am. J. Gastroenterol., c. 79, ss. 28–31, 1984.

[9] N. V. Chawla, K. W. Bowyer, L. O. Hall, ve W. P. Kegelmeyer, "SMOTE: Synthetic minority over-sampling technique," J. Artif. Intell. Res., c. 16, ss. 321–357, 2002.