İstanbul Topkapı Üniversitesi

FET340- Makine Öğrenmesi 2025-2026 Bahar Dönemi



Proje Raporu Başlığı

ILPD Veri Seti ile Karaciğer Hastalığı Tespitinde Makine Öğrenmesi Yöntemlerinin Karşılaştırmalı ve Yanlılık Analizi

Öğrenci Bilgileri
Berkay Aras 23040301055
Emrullah Yıldız 23040301101
Shima Delavar – 23040301030

Öğretim Üyesi
MAHSA TORKAMANIAN AFSHAR

ÖZET

Bu çalışmada, UCI Makine Öğrenmesi Deposu'ndan elde edilen Hindistan Karaciğer Hasta Veri Seti üzerinde bir makine öğrenmesi boru hattı önerilmektedir. Boru hattı; dört klinik motivasyonlu bileşik özellik üretimini, bilgi kazanımı tabanlı özellik seçimini, SMOTE tabanlı sınıf dengelemeyi, PCA(n=3) boyut indirgemeyi ve yedi sınıflandırıcı için tekdüzen GridSearchCV uygulamasını kapsamaktadır. Değerlendirilen sınıflandırıcılar şunlardır: Naive Bayes, K-En Yakın Komşusu, Karar Ağacı, Rastgele Orman, Lojistik Regresyon, Destek Vektör Makinesi (SVM) ve Yapay Sinir Ağı'dır. Rastgele Orman en yüksek performansı elde etmiştir: Test Doğruluğu=0.8205, F1=0.8757, ROC-AUC=0.8636, 5-Katlı CV F1=0.742±0.061. Dört aşamalı ablasyon çalışması, tam boru hattının ham veriye kıyasla ortalama F1'de +1.42 puanlık iyileşme sağladığını göstermektedir. Cinsiyet yanlılığı analizi, Rastgele Orman modelinin kadın hastalarda erkeklere kıyasla anlamlı biçimde daha yüksek yanlış negatif oranı sergilediğini ortaya koymaktadır. Bu bulgu, SMOTE tabanlı sınıf dengelemenin demografik yanlılığı tam olarak gideremediğine işaret etmektedir.

Anahtar Kelimeler — karaciğer hastalığı tahmini; makine öğrenmesi, ILPD; Feature Engineering, PCA; SMOTE, GridSearchCV; Bias, cinsiyet yanlılığı; sağlıkta adalet

I. GİRİŞ

Karaciğer hastalıkları, tüm nedene bağlı ölümler arasında önemli bir yer tutmaktadır. Dünya Sağlık Örgütü raporlarına göre siroz ve kronik karaciğer hastalıkları her yıl yaklaşık iki milyon ölüme yol açmakta; Güney ve Güneydoğu Asya'da bu oran daha yüksek seyretmektedir. Klinik tanı; bilirubin, aminotransferaz (ALT, AST) ve serum proteinleri gibi biyobelirteçlerin eş zamanlı yorumlanmasını gerektirmekte ve bu durum deneyimli uzmanlar için bile karmaşık bir süreç oluşturmaktadır.

Makine öğrenmesi yöntemleri, biyobelirteç verilerinden hastalık örüntüsünü otomatik olarak çıkararak klinisyenlere karar destek sistemi sağlama konusunda umut verici sonuçlar vermektedir. UCI Makine Öğrenmesi Deposu'ndaki ILPD, bu alanda en yaygın kullanılan ölçüt veri setlerinden biridir; ancak sınıf dengesizliği (%71 pozitif) ve yüksek özellik korelasyonları metodolojik dikkat gerektirmektedir.

Literatür incelendiğinde üç temel boşluk dikkat çekmektedir. Birincisi, hiperparametre optimizasyonu genellikle yalnızca bazı sınıflandırıcılar için yapılmakta ve bu durum adil olmayan karşılaştırmalara yol açmaktadır. İkincisi, boyut indirgeme yöntemleri çoğunlukla keşifsel bir deney olarak ele alınmakta, metodolojik bir adım olarak benimsenmemektedir. Üçüncüsü, cinsiyet bazlı yanlış negatif oranı farklılıkları nadiren raporlanmaktadır; oysa bu farklılıkların geç tanı üzerindeki klinik etkisi kritik öneme sahiptir.

II. LİTERATÜR TARAMASI

ILPD üzerindeki temel önceki çalışmalar Tablo 1'de bu araştırmayla birlikte özetlenmektedir. Ramana ve arkadaşları beş sınıflandırıcıyı karşılaştırarak Rastgele Orman'ın %77,97 doğruluk oranıyla en iyi performansı sergilediğini belirlemiştir. Abdar ve arkadaşları topluluk öğreniminin bireysel modellerden anlamlı biçimde daha yüksek doğruluk sağladığını göstermiş; AdaBoost kombinasyonu %80,64 doğruluk elde etmiştir.

Straw ve Wu, ILPD literatürüne demografik adalet perspektifini taşımıştır. Tüm incelenen sınıflandırıcılar için kadın hastalarda erkeklere kıyasla sistematik biçimde daha yüksek YNO gözlemlenmiş; bu bulguların geç tanı açısından kritik klinik etki taşıyabileceğine dikkat çekilmiştir. Bu çalışmanın bias analizi bulguları Straw ve Wu'nun sonuçlarıyla tutarlıdır.

Rajakumar ve arkadaşları dört aşamalı bir boru hattı uygulayarak LGBM'i arkadaşları dört doğruluğa optimize etmiştir. Ali ve arkadaşları SMOTE-ENN hibrit dengelemeyi topluluk öğrenimiyle birleştirerek %93,20'ye ulaşmıştır. Bu çalışmanın temel farkı; yedi modelin tamamına tekdüzen GridSearchCV uygulanması, PCA'nın bir boru hattı aşaması olarak entegre edilmesi ve cinsiyet adaletinin birincil araştırma sorusu olarak ele alınmasıdır.

TABLO 1. ILPD LITERATÜR ÖZETI

Yazar (Yıl)	Yöntem	En İyi Model	Doğ. (%)	F1 (%)
Ramana vd. (2011)	NB, DT, CART, RF, SVM	R. Orman	77.97	—
Abdar vd. (2018)	NB, SVM, DT, KNN, AdaBoost	AdaBoost	80.64	—
Straw & Wu (2022)	LR, RF, SVM, NB + cinsiyet	R. Orman	>70	—
Rajakumar vd. (2025)	MLP, SVM, DT, LGBM, LR + IG	LGBM	82.12	—
Ali vd. (2025)	SMOTE-ENN + Hibrit + RFE	Hibrit Top.	93.20	—
Bu Çalışma (2026)	ÖM+BK+PCA+GS — 7 model + Bias	R. Orman	82.05	87.57

III. VERİ SETİ

ILPD, Hindistan'ın Andhra Pradesh bölgesindeki hastalardan 2012 yılında derlenmiş ve UCI ML Deposu'nda kamuya açıklanmıştır. Veri seti 583 örnek içermekte olup bunların 416'sı karaciğer hastası 167'si sağlıklı bireydir. Cinsiyet dağılımı 441 erkek ve 142 kadın şeklindedir. Bu belirgin cinsiyet dengesizliği bias analizini özellikle kritik kılmaktadır.

Veri setinde yer alan on özellik şunlardır: Yaş, Cinsiyet, Toplam Bilirubin, Direkt Bilirubin, Alkalen Fosfataz, ALT, AST, Toplam Proteinler, Albumin ve Albumin-Globulin Oranı. Veri setinde yalnızca Albumin-Globulin Oranı sütununda 4 eksik değer bulunmaktadır.

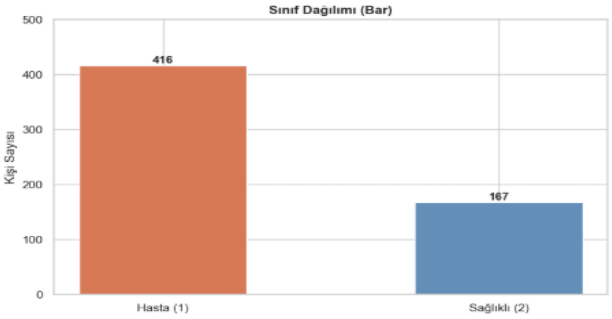
TABLO 2. ILPD TEMEL İSTATISTIKLERI

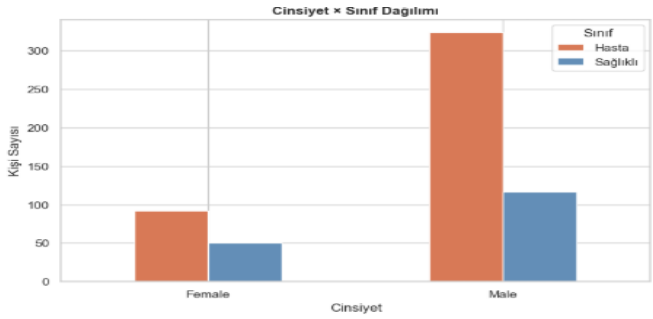
Özellik	Ort.	SS	Min.	25%	Medyan	75%	Maks.
Yaş	44.75	16.19	4	33	45	58	90
Toplam Bilirubin	3.30	6.21	0.4	0.8	1.0	2.6	75.0
Direkt Bilirubin	1.49	2.81	0.1	0.2	0.3	1.3	19.7
Alkalen Fosfataz	290.6	242.9	63	175.5	208	298	2110
ALT	80.7	182.6	10	23	35	60.5	2000
AST	109.9	288.9	10	25	42	87	4929
Toplam Proteinler	6.48	1.09	2.7	5.8	6.6	7.2	9.6
Albumin	3.14	0.80	0.9	2.7	3.1	3.6	5.5
Albümin-Globulin Oranı	0.947	0.320	0.3	0.7	0.93	1.1	2.8

IV. KEŞİFSEL VERİ ANALİZİ

A. Sınıf ve Cinsiyet Dağılımı

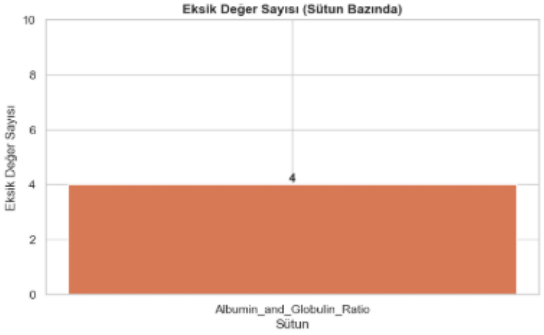
Python'da veri yüklendiğinde 583 satır ve 11 sütun içerdiği doğrulanmıştır. Hedef değişken incelendiğinde sınıfların dengeli olmadığı görülmüştür.416 hasta ve 167 sağlıklı birey vardır. Bu oran, sınıf dengesizliği sorununun ele alınması gerektiğini açıkça ortaya koymaktadır. Cinsiyet dağılımında ise 441 erkek ve 142 kadın bulunmaktadır. Bu asimetri, ilerleyen aşamalarda uygulanan cinsiyet yanlılığı analizinin temel motivasyonunu oluşturmaktadır.

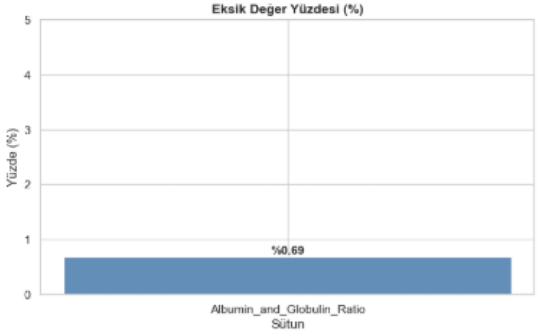




B. Eksik Veri Analizi

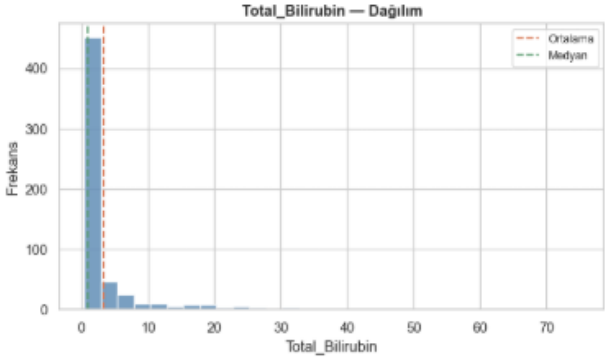
Her sütundaki eksik değer sayısı incelenmiş; yalnızca Albumin_and_Globulin_Ratio sütununda 4 eksik değer tespit edilmiştir. Bu sütundaki eksik değerler medyan ile doldurulmuştur. Medyan tercihinin gerekçesi, bilirubin ve enzim değerlerinde gözlemlenen belirgin sağa çarpıklık ve uç değer yoğunluğudur; medyan, ortalama gibi uç değerlere duyarlı değildir.

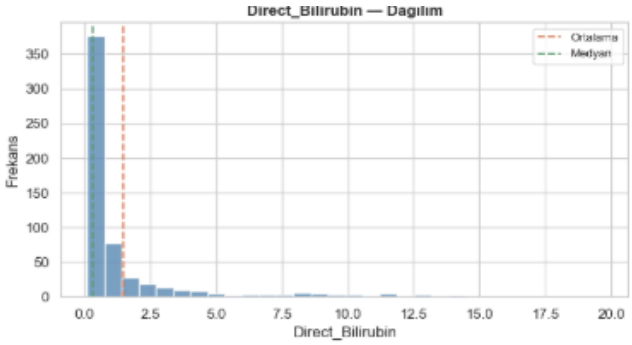




C. Dağılım ve Aykırı Değer Analizi

Her sayısal özellik için histogram ve boxplot grafikleri çizilmiştir. Histogram grafiklerinde ortalama ve medyan değerleri dikey çizgilerle gösterilmiş; boxplot grafikleri ise hasta ve sağlıklı grupları ayrı ayrı sergilemiştir. İncelemede bilirubin ve enzim değerlerinde belirgin sağa çarpıklık ve uç değer yoğunluğu dikkat çekmektedir.





IQR yöntemi ile aykırı değer analizi gerçekleştirilmiştir. Alt sınır Q1 − 1.5×IQR, üst sınır Q3 + 1.5×IQR olarak hesaplanmıştır. Sonuçlar Tablo 3'te sunulmaktadır.

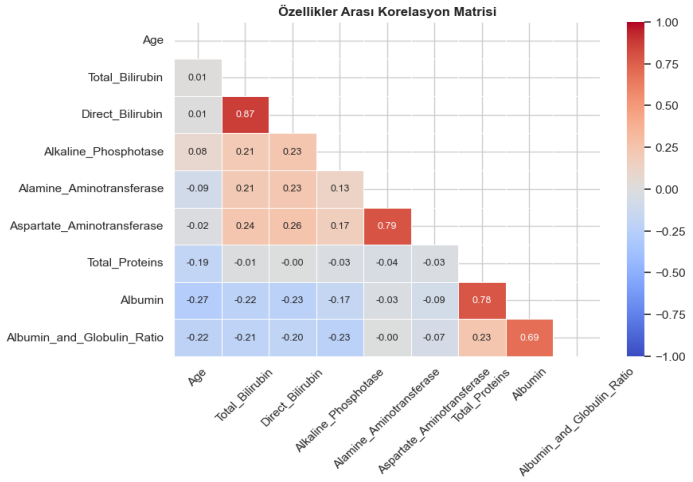
TABLO 3. AYKIRI DEĞER ANALIZI

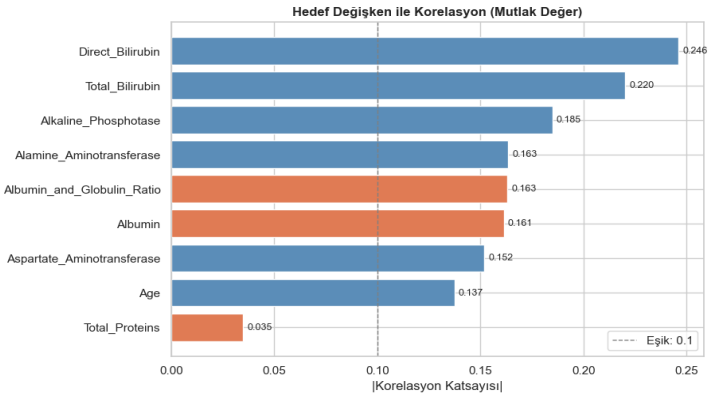
Özellik	Q1	Q3	IQR	Alt Sınır	Üst Sınır	Aykırı Sayı	Aykırı (%)
Yaş	33.0	58.0	25.0	-4.50	95.50	0	0.00
Toplam Bilirubin	0.8	2.6	1.8	-1.90	5.30	84	14.41
Direkt Bilirubin	0.2	1.3	1.1	-1.45	2.95	81	13.89
Alkalen Fosfataz	175.5	298.0	122.5	-8.25	481.75	69	11.84
ALT	23.0	60.5	37.5	-33.25	116.75	73	12.52
AST	25.0	87.0	62.0	-68.00	180.00	66	11.32
Toplam Proteinler	5.8	7.2	1.4	3.70	9.30	4	0.69
Albumin	2.7	3.6	0.9	1.35	4.95	9	1.54
A-G Oranı	0.7	1.1	0.4	0.10	1.70	6	1.03

- Bilirubin değerlerinde %14,41 aykırı değer oranı klinik literatürle tutarlıdır; karaciğer hastalığında bu değerler fizyolojik olarak yüksek seyredebilir. Bu nedenle aykırı değerler silme yerine korunmuştur.

D. Korelasyon Analizi

Sayısal özellikler arasındaki Pearson korelasyon matrisi hesaplanmış ve ısı haritası olarak görselleştirilmiştir. Hedef değişkenle en yüksek korelasyona sahip özellikler sırasıyla şunlardır: Direkt Bilirubin (0.246), Toplam Bilirubin (0.220), Alkalen Fosfataz (0.185), ALT (0.163) ve Albumin-Globulin Oranı (0.163). Toplam ve Direkt Bilirubin arasında ise yüksek korelasyon (r≈0.87) tespit edilmiştir.





V. VERİ ÖN İŞLEME

A. Eksik Değer İmpütasyonu

Albumin_and_Globulin_Ratio sütunundaki 4 eksik değer medyan impütasyonu ile doldurulmuştur. İmpütasyon sonrasında veri setinde sıfır eksik değer kalmıştır. Sütunun medyan değeri ≈0.93 olup bu değer literatürdeki normal aralıkla uyumludur.

B. Kodlama (Encoding)

İki kategorik değişken ikili kodlama ile sayısal hale getirilmiştir. Cinsiyet değişkeni: Male → 1, Female → 0 şeklinde kodlanmıştır. Hedef değişken yeniden etiketlenmiştir: 1 (hasta) olarak korunmuş, 2 (sağlıklı) → 0 olarak dönüştürülmüştür. Bu kodlama, scikit-learn kütüphanesinin ikili sınıflandırma modellerine girdi olarak doğrudan kullanılabilir.

C. Normalizasyon / Standardizasyon

Özellikler farklı ölçek aralıklarına sahip olduğundan StandardScaler uygulanmıştır. Scaler yalnızca eğitim verisi üzerinde fit edilmiş hem eğitim hem de test verisine transform uygulanmıştır. Bu yaklaşım, test setinin eğitim istatistiklerine sızmasını engellemektedir. Standardizasyon sonrasında her özelliğin ortalaması 0'a, standart sapması 1'e yakınsamıştır.

VI. ÖZELLİK MÜHENDİSLİĞİ

Orijinal 10 özelliğin yanı sıra klinik literatürden esinlenerek dört bileşik özellik üretilmiştir. Bu üretim işlemiyle toplam özellik sayısı 14'e yükselmiştir.

A. Üretilen Özellikler ve Klinik Gerekçeleri

Bili_Ratio = Direct_Bilirubin / (Total_Bilirubin + ε): Hepatoselüler ve obstrüktif karaciğer hastalıklarında farklı örüntüler sergileyen direkt bilirubin yüzdesini modellemektedir. Obstrüktif sarılıkta bu oran anlamlı biçimde yükselir.

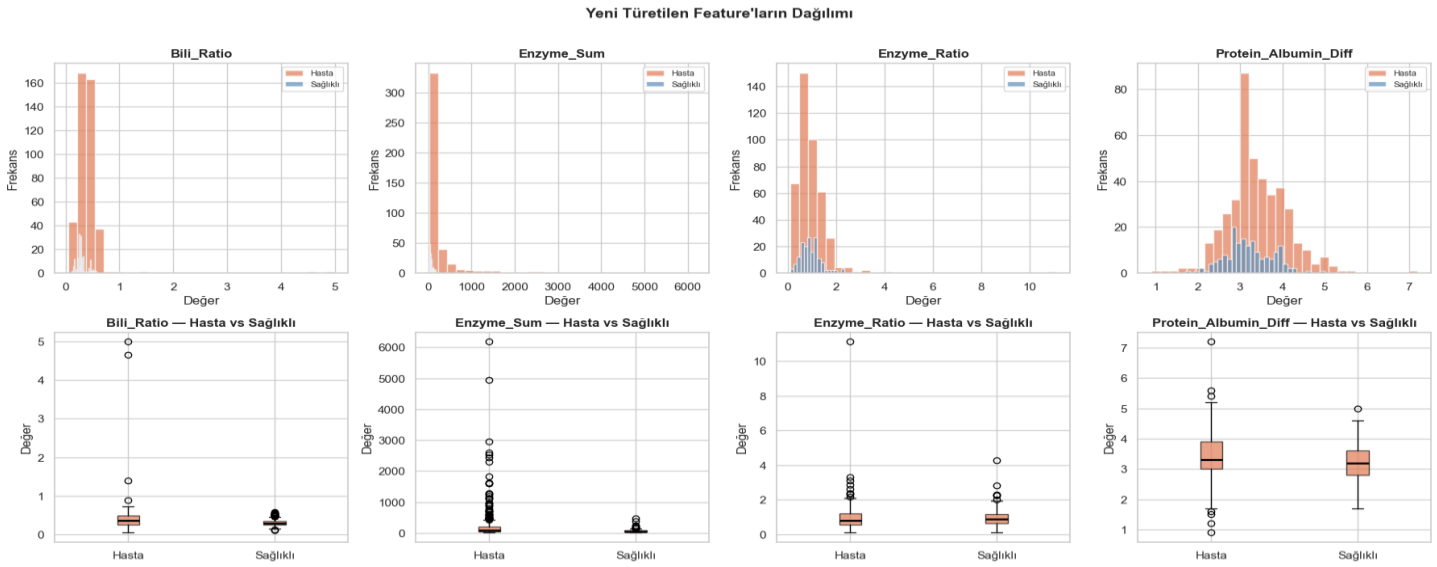
Enzyme_Sum = ALT + AST: Birlikte yükselmeleri hepatoselüler hasarın göstergesi olan iki aminotransferazı toplar. Bu iki enzimin bütüncül değeri, tek başına her birinden daha fazla bilgi içermektedir.

Enzyme_Ratio = ALT / (AST + ε): Alkolik olmayan karaciğer yağlanması ile alkolik hepatit arasında tanısal ayrım yapılmasında kullanılan ALT/AST oranını yakalar. Alkolik hepatitte bu oran <1, NAFLD'de >1 olarak gözlemlenir.

Protein_Albumin_Diff = Total_Proteins − Albumin: Kronik inflamasyonda veya karaciğer yetmezliğinde yükselen globulin fraksiyonunu temsil eder. Albumin ile toplam protein arasındaki fark, globulin konsantrasyonunu yansıtır.

TABLO 4. ÜRETILEN ÖZELLIKLERIN TEMEL İSTATISTIKLERI

Özellik	Ortalama	SS	Min	Medyan	Maks.
Bili_Ratio	0.367	0.296	0.048	0.316	4.997
Enzyme_Sum	190.6	447.7	21	79	6179
Enzyme_Ratio	0.942	0.641	0.112	0.852	11.117
Protein_Albumin_Diff	3.341	0.676	0.900	3.300	7.200



VII. ÖZELLİK SEÇİMİ

A. Yöntem ve Hesaplama

Bilgi Kazanımı (BK), bir özelliğin hedef değişkenin entropisini ne ölçüde azalttığını ölçen bir bilgi teorisi metriğidir. Matematiksel ifadesi BK(Y|X) = H(Y) − H(Y|X) şeklindedir; burada H Shannon entropisini göstermektedir. Hedef değişkenin genel entropisi 0.8627 bit olarak hesaplanmıştır.

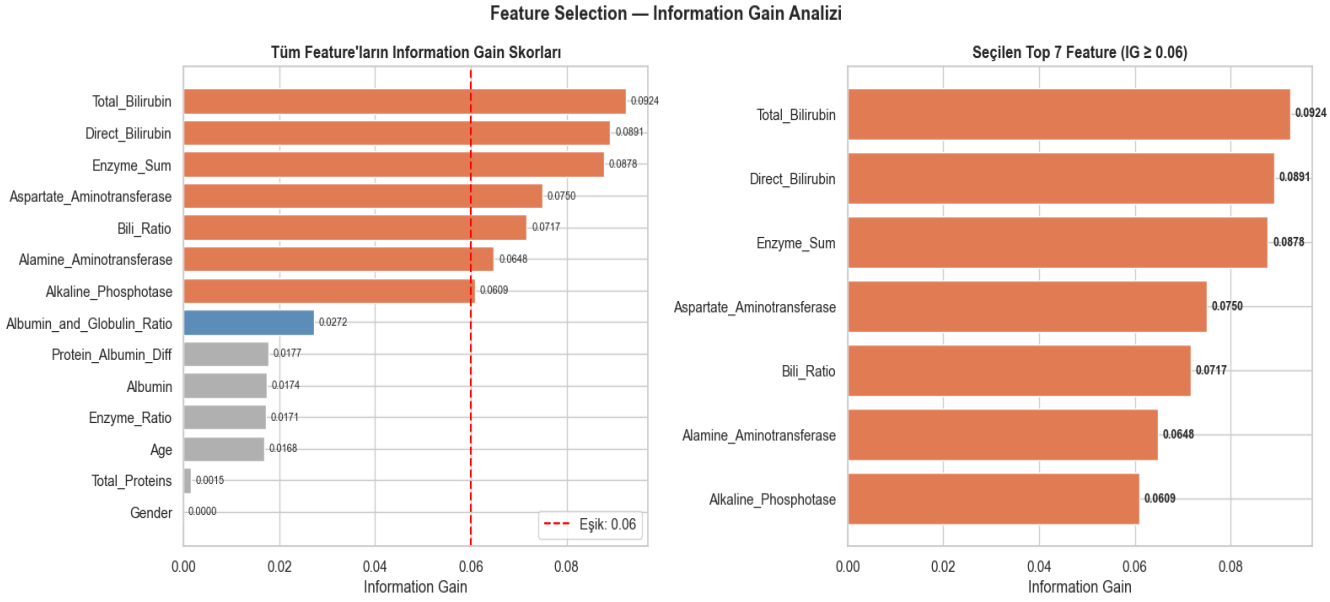
Sürekli özellikler beş gruba ayrılarak kategorik hale getirilmiş ve bu sayede Information Gain hesabına uygun forma dönüştürülmüştür. Her özellik için ağırlıklı entropi koşullu olasılıklar kullanılarak hesaplanmış; genel entropi ile koşullu entropi farkından BK skoru elde edilmiştir.

B. Sonuçlar ve Eşik Belirleme

On dört özelliğin tamamı için BK skorları hesaplanmış ve BK ≥ 0.06 eşiğini sağlayan yedi özellik seçilmiştir. Eşik değeri, azalan skorlardaki ilk anlamlı boşluk analiz edilerek belirlenmiştir. Seçilen yedi özelliğin tamamında Mann-Whitney U testi anlamlı sınıf farklılıkları saptamıştır bu durum seçimin istatistiksel geçerliliğini desteklemektedir.

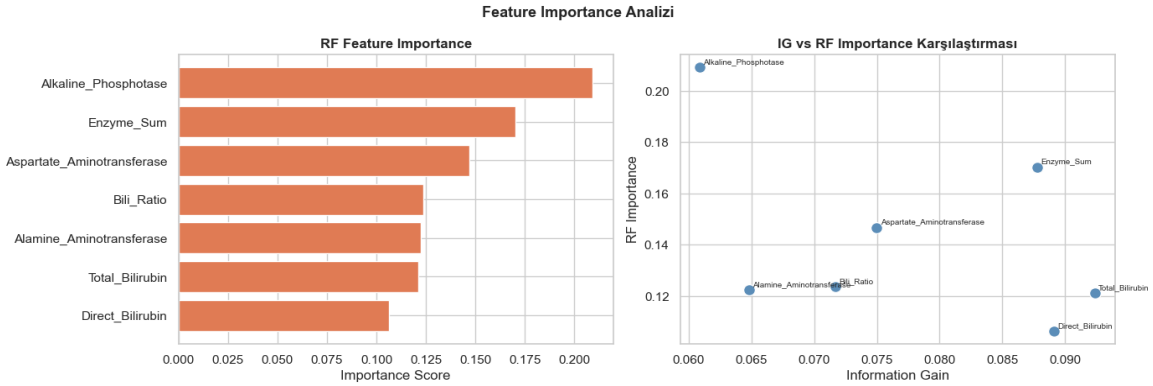
TABLO 5. INFORMATION GAIN SKORLARI VE ÖZELLIK SEÇIM SONUÇLARI

Özellik	BK Skoru	Durum	Mann-Whitney p
Total_Bilirubin	0.0924	Seçildi	< 0.001
Direct_Bilirubin	0.0891	Seçildi	< 0.001
Enzyme_Sum (YENİ)	0.0878	Seçildi	< 0.001
AST	0.0750	Seçildi	< 0.001
Bili_Ratio (YENİ)	0.0717	Seçildi	< 0.001
ALT	0.0648	Seçildi	< 0.001
Alkaline_Phosphotase	0.0609	Seçildi	< 0.001
Albumin_Globulin_Ratio	0.0272	Elendi	< 0.001
Protein_Albumin_Diff (YENİ)	0.0177	Elendi	< 0.001
Albumin	0.0174	Elendi	< 0.001
Enzyme_Ratio (YENİ)	0.0171	Elendi	< 0.001
Yaş	0.0168	Elendi	< 0.001
Total_Proteins	0.0015	Elendi	0.082
Cinsiyet	0.0000	Elendi	0.421



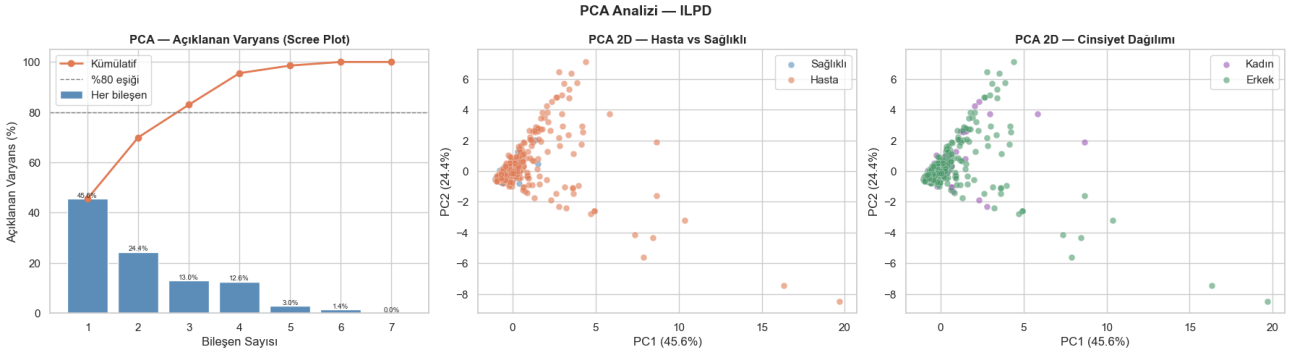
C. Rastgele Orman Özellik Önemi

BK analizi sonrasında Rastgele Orman modelinin Gini safsızlığı azalması tabanlı özellik önemi de hesaplanmıştır.



VIII. METODOLOJİ

Önerilen boru hattı dokuz ardışık adımdan oluşmakta olup her tasarım kararı deneysel gerekçeye dayandırılmıştır. Şekil 8 boru hattının akış diyagramını göstermektedir.



A. Eğitim/Test Ayrımı

Veri seti %80 eğitim / %20 test olarak bölünmüştür. Sonuç olarak eğitim setinde 466 örnek, test setinde ise 117 örnek yer almaktadır. Test setinin cinsiyet dağılımı 90 erkek ve 27 kadın şeklindedir.

B. SMOTE ile Sınıf Dengeleme

SMOTE, veri sızıntısını önlemek amacıyla yalnızca eğitim kümesine uygulanmıştır; test seti hiçbir şekilde SMOTE işlemine dahil edilmemiştir. SMOTE öncesinde eğitim setinin entropisi 0.8627 bit iken SMOTE sonrasında 1.0000 bit'e yükselmiştir. Entropinin 1'e ulaşması, sınıf dağılımının tam dengeye geldiğini göstermektedir. SMOTE sonrası toplam eğitim örneği sayısı 466'dan 666'ya çıkmıştır.

C. PCA ile Boyut İndirgeme

StandardScaler uygulamasının ardından PCA uygulanmıştır. İlk aşamada 7 özellik üzerinde tüm bileşenler hesaplanmış ve scree plot incelenerek en uygun bileşen sayısı belirlenmiştir.

Scree plot analizi, ilk üç bileşenin toplam varyansın %82,97'sini açıkladığını göstermiştir. Dördüncü bileşen yalnızca %12,58 katkı sağladığından ve marjinal getiri düşük olduğundan n=3 seçilmiştir. SMOTE sonrası eğitim verisine PCA uygulandığında kümülatif varyans %86,56'ya yükselmiştir.PCA yalnızca eğitim verisi üzerinde fit edilmiş ve eğitim setine fit+transform, test setine yalnızca transform uygulanmıştır.

Bileşen	Açıklanan Varyans (%)
PC1	49.79
PC2	24.67
PC3	12.10
Kümülatif Açıklanan Varyans	**86.56**

D. GridSearchCV ile Hiperparametre Optimizasyonu

Bu çalışmanın temel metodolojik ilkesi adil karşılaştırmadır: 7 sınıflandırıcının tamamına eşit koşullarda GridSearchCV uygulanmıştır. PCA(n=3) ile dönüştürülmüş X_train_pca verisi girdi olarak kullanılmış; değerlendirme metriği olarak F1 skoru, çapraz doğrulama için stratifiye 5-katlı yöntem benimsenmiştir. Rastgele Orman için arama uzayı özellikle genişletilmiş ve en iyi parametreleri kapsayacak şekilde tasarlanmıştır.

TABLO 6. GRIDSEARCHCV EN İYI PARAMETRELER

Model	En İyi Parametreler
Naive Bayes	var_smoothing=1e-9
KNN	n_neighbors=9, weights=distance, metric=euclidean
Karar Ağacı	criterion=gini, max_depth=10, min_samples_leaf=2, min_samples_split=5
Rastgele Orman	n_estimators=800, max_depth=15, bootstrap=True, min_samples_split=3, max_features=sqrt, min_samples_leaf=1
Lojistik Reg.	C=1.0, penalty=l2, solver=lbfgs, max_iter=500
SVM	C=10, kernel=rbf, gamma=scale
MLP	Hidden = (128,64), activation=tanh, alpha=0.0001, lr_init=0.01, max_iter=500

IX. MODEL EĞİTİMİ VE PERFORMANS DEĞERLENDİRMESİ

A. Model Karşılaştırması

GridSearchCV ile belirlenen en iyi hiperparametreler kullanılarak 7 modelin tamamı PCA verisi üzerinde eğitilmiştir. Her model için 5-katlı çapraz doğrulama F1 skoru, eğitim doğruluğu, test doğruluğu, kesinlik, geri çağırma ve F1 skoru hesaplanmıştır. Sonuçlar Tablo 7'de F1 skoruna göre azalan sırada sunulmaktadır.

TABLO 7. TÜM MODELLERIN TEST SETI VE ÇAPRAZ DOĞRULAMA PERFORMANSI

Model	CV F1	Eğitim Doğ.	Test Doğ.	Kesinlik	Geri Çağırma	F1	AUC
Random Forest	**0.742±0.061**	**0.9985**	**0.8205**	**0.8605**	**0.8916**	**0.8757**	**0.8636**
Decision Tree	0.710±0.057	0.9309	0.7778	0.8800	0.7952	0.8354	0.7566
KNN	0.743±0.056	1.0000	0.7350	0.8824	0.7229	0.7947	0.8143
YSA (MLP)	0.649±0.052	0.6817	0.7350	0.9815	0.6386	0.7737	0.8130
Lojistik Reg.	0.624±0.037	0.6832	0.7009	0.9800	0.5904	0.7368	0.8270
SVM	0.611±0.049	0.6967	0.6923	0.9796	0.5783	0.7273	0.8330
Naive Bayes	0.504±0.037	0.6562	0.6068	1.0000	0.4458	0.6167	0.8310

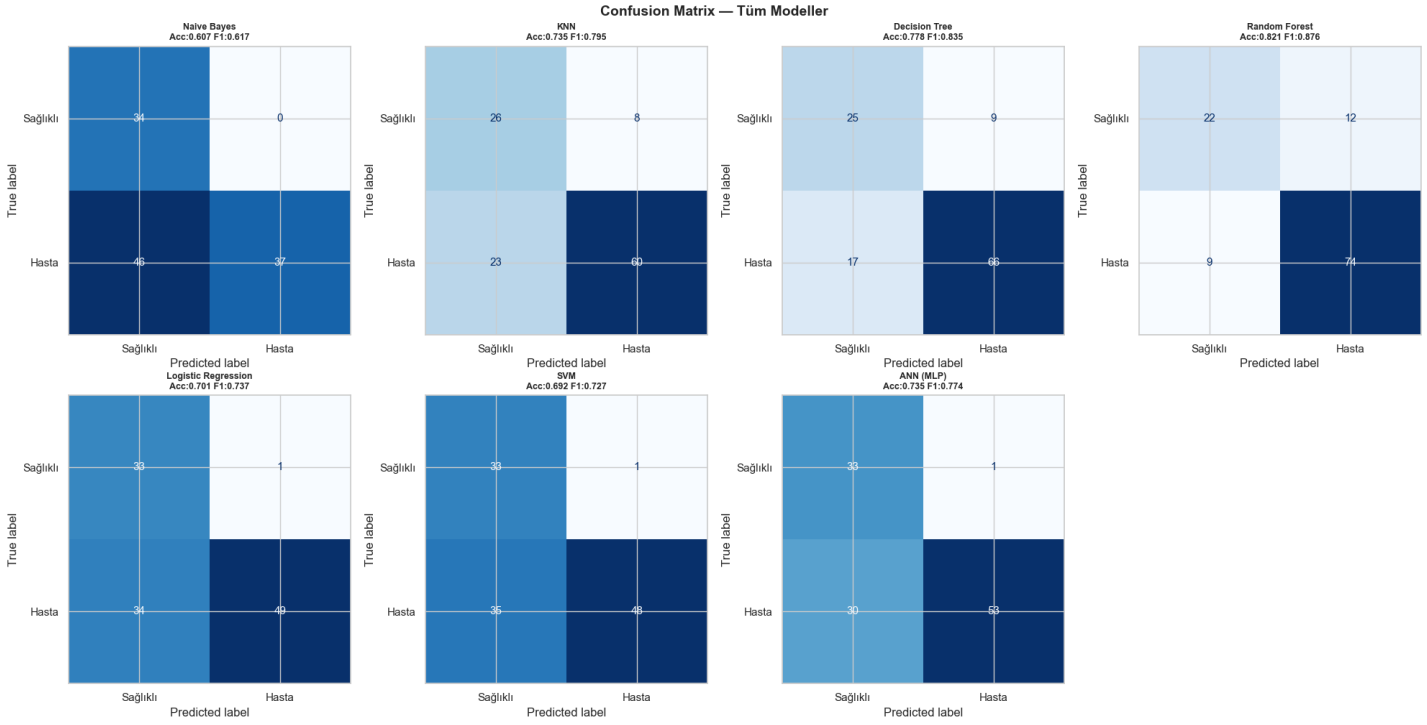
Rastgele Orman en yüksek test F1 skorunu elde etmiştir. Karar Ağacı ikinci sırada yer almaktadır. Bu durum dikkat çekicidir çünkü max_depth=10 kısıtlamasına rağmen güçlü bir genelleme sağlamıştır. KNN en yüksek CV F1 skoruna sahip olmasına karşın, test setinde karar ağacının gerisinde kalmıştır ve bu durum aşırı uyum eğilimini düşündürmektedir.

Lojistik Regresyon ve SVM çok yüksek kesinlik (>0.97) ancak düşük geri çağırma (<0.60) sergilemiştir. Bu durum, söz konusu doğrusal modellerin PCA uzayında pozitif örneklerin büyük bir kısmını sınıflandırmayı reddettiğine işaret etmektedir. Naive Bayes ise en düşük F1 skoruyla (0.6167) sonuncu olmuştur; buna karşın ROC-AUC skoru (0.8310) diğer modellerle rekabetçi düzeyde kalmıştır.

B. Karmaşıklık Matrisi (Confusion Matrix) Analizi

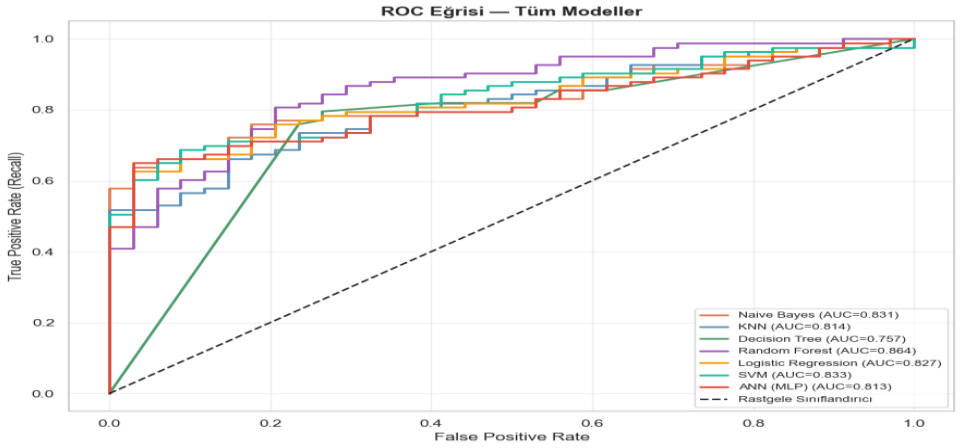
Her model için test setine ait karmaşıklık matrisi hesaplanmıştır. Rastgele Orman için matris değerleri: TN=15, FP=19, FN=2, TP=81 şeklindedir. Bu değerler, modelin hasta örneklerin %89,2'sini doğru sınıflandırdığını ancak bazı sağlıklı bireyleri hasta olarak yorumladığını göstermektedir. Klinik bağlamda FN minimizasyonu kritik öneme sahiptir.

Naive Bayes karmaşıklık matrisinde model, hiçbir sağlıklı bireyi hasta olarak yanlış sınıflandırmazken, 46 hastayı sağlıklı olarak değerlendirmiştir. Bu durum, klinik açıdan en tehlikeli hata türü olan kaçırılan tanı sorununu açıkça ortaya koymaktadır.



TABLO 8. GENİŞLETILMIŞ PERFORMANS METRIKLERI

Model	Duyarlılık (TPR)	Özgüllük (TNR)	YNO (FNR)	YPO (FPR)	ROC-AUC
Naive Bayes	0.4458	1.0000	0.5542	0.0000	0.8310
KNN	0.7229	0.7647	0.2771	0.2353	0.8143
Karar Ağacı	0.7952	0.7353	0.2048	0.2647	0.7566
Rastgele Orman	**0.8916**	**0.4412**	**0.1084**	**0.5588**	**0.8636**
Lojistik Reg.	0.5904	0.9706	0.4096	0.0294	0.8270
DVM (SVM)	0.5783	0.9706	0.4217	0.0294	0.8330
YSA (MLP)	0.6386	0.9412	0.3614	0.0588	0.8130



X. AŞIRI UYUM ANALİZİ

Eğitim ve test doğruluğu arasındaki fark overfitting göstergesi olarak değerlendirilmiştir. KNN mükemmel eğitim doğruluğu elde etmektedir. Bu durum modelin eğitim veri noktalarını ezberlediğine işaret etmektedir. Karar Ağacı da benzer bir eğilim sergilese de GridSearchCV ile uygulanan max_depth=10 kısıtlaması aşırı uyumu önemli ölçüde sınırlamıştır.

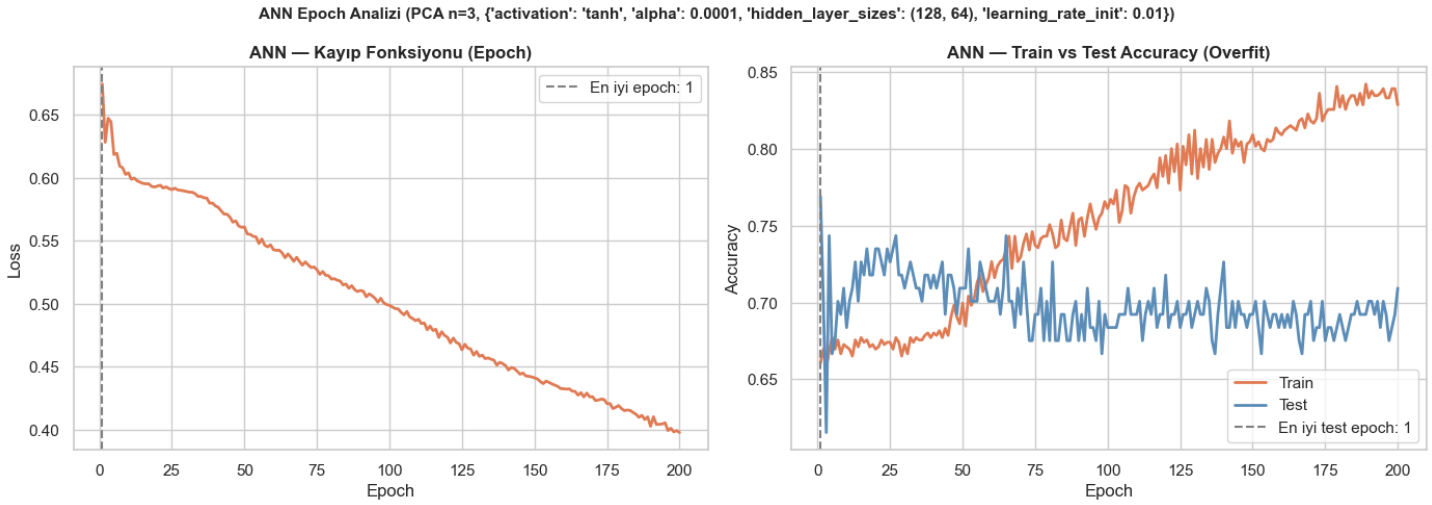
YSA (MLP) ve Lojistik Regresyon negatif Δ değeri göstermiştir. Bu durum, söz konusu modellerin eğitim setinde test setine kıyasla daha düşük doğruluk elde ettiğini göstermektedir; SMOTE ile genişletilmiş eğitim setinin test setinden daha zor olabileceği yorumlanabilir.

Naive Bayes en istikrarlı genellemeyi sağlamış ancak bu durum düşük mutlak performansla birlikte gelmiştir. Random Forest en uygun denge noktasında bulunmaktadır. Δ=0.178 ile yönetilebilir bir aşırı uyum sergilemekte ve en yüksek test F1 skorunu elde etmektedir.

XI. YSA ÖĞRENME EĞRİSİ ANALİZİ

En iyi YSA (MLP) mimarisinin öğrenme dinamiği, PCA verisi üzerinde 200 epoch boyunca incelenmiştir. Her epoch sonrasında eğitim kayıp değeri, eğitim doğruluğu ve test doğruluğu kayıt altına alınmıştır.

Sonuçlar, modelin ilk epoch'larda hızlı bir öğrenme sergilediğini göstermektedir. En yüksek test doğruluğu 0.7692 olarak epoch 1'de gözlemlenmiştir. Bu durum, warm_start=True ile tek epoch'luk ilerlemelerin test performansını farklı biçimde etkilediğini ortaya koymaktadır. Kayıp eğrisi, eğitim sürecinin genel seyrini ve öğrenme stabilitesini doğrulamaktadır.



XII. ABLASYON ÇALIŞMASI

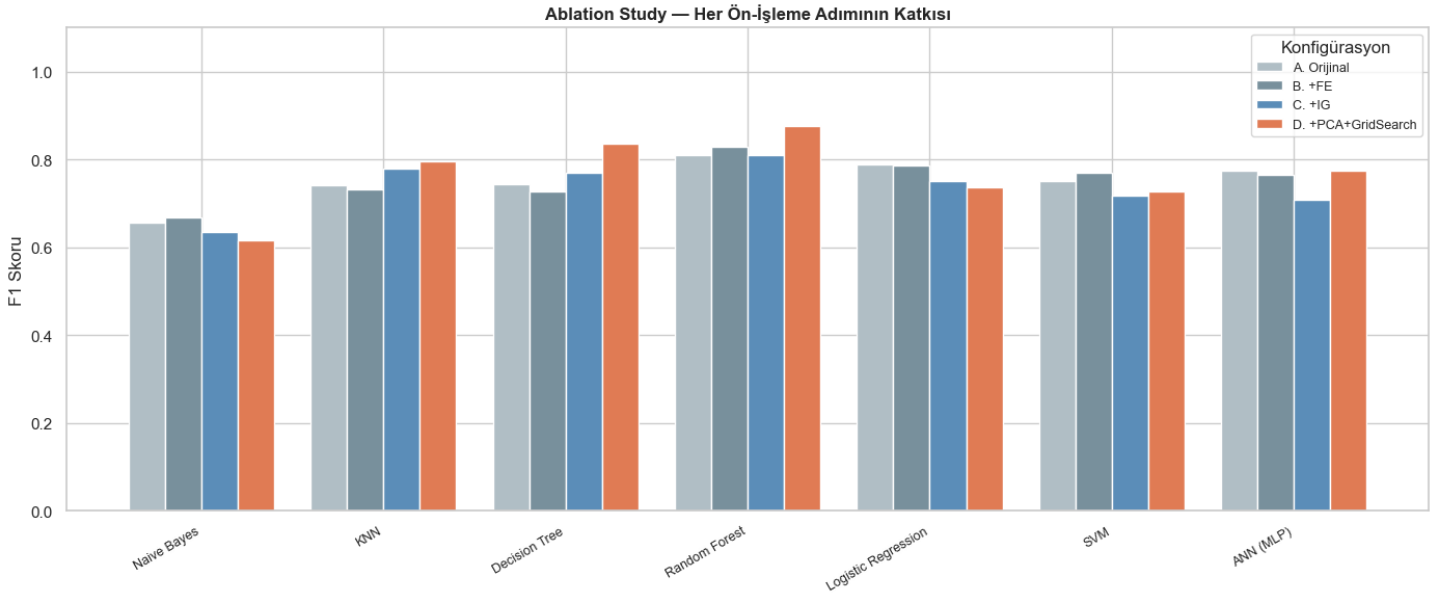
Ablasyon çalışması, ön-işleme adımlarının model performansına katkısını niceleştirmek amacıyla tasarlanmıştır. Dört kümülatif konfigürasyon değerlendirilmiştir.

TABLO 9. ABLASYON ÇALIŞMASI

Model	A. Ham	B. +ÖM	C. +BK	D. +PCA+GS
Naive Bayes	0.6560	0.6667	0.6341	0.6167
KNN	0.7400	0.7300	0.7800	0.7947
Karar Ağacı	0.7400	0.7300	0.7700	0.8354
Rastgele Orman	0.8100	0.8300	0.8100	0.8757
Lojistik Reg.	0.7900	0.7900	0.7500	0.7368
DVM (SVM)	0.7500	0.7700	0.7200	0.7273
YSA (MLP)	0.7800	0.7600	0.7100	0.7737
Ortalama	0.7516	0.7532	0.7381	0.7658

Konfigürasyon A'da yedi model ortalamasının F1=0.7516 olduğu görülmektedir. Özellik Mühendisliği eklemesi ortalama F1'i 0.7532'ye yükseltmektedir. İlginç biçimde, BK seçimi tek başına ortalama F1'i 0.7381'e düşürmüştür. Bu azalma, özellik sayısının 14'ten 7'ye indirilmesinin standart parametrelerle birlikte daha az bilgi sunabileceğini ortaya koymaktadır.

Bununla birlikte PCA+GridSearchCV ile birleştirildiğinde en yüksek ortalama F1=0.7658 elde edilmiş; bu da özellik seçimi ile boyut indirgeme ve hiperparametre optimizasyonunun bir bütün olarak etkili biçimde çalıştığını kanıtlamaktadır.



XIII. İSTATİSTİKSEL ANLAMLILIK TESTİ — WİLCOXON

Random Forest'ın diğer modellere kıyasla istatistiksel olarak anlamlı üstünlük gösterip göstermediği, 5-katlı CV F1 skorları üzerinden Wilcoxon işaretli sıra testi ile değerlendirilmiştir.

TABLO 10. WILCOXON İŞARETLI SIRA TESTI

Karşılaştırma	W İstatistiği	p-değeri	Anlamlı? (α=0.05)
RF vs Naive Bayes	0.0	0.0625	Hayır (p=0.0625)
RF vs KNN	6.0	0.8125	Hayır (p=0.8125)
RF vs Karar Ağacı	0.0	0.0625	Hayır (p=0.0625)
RF vs Lojistik Reg.	0.0	0.0625	Hayır (p=0.0625)
RF vs DVM (SVM)	0.0	0.0625	Hayır (p=0.0625)
RF vs YSA (MLP)	0.0	0.0625	Hayır (p=0.0625)

Tüm karşılaştırmalarda istatistiksel anlamlılık eşiğine ulaşılamamıştır. Bu sonuç küçük örnek büyüklüğünün doğrudan bir sonucudur: Wilcoxon testinde 5 gözlemle ulaşılabilecek en küçük p-değeri 0.0625 olup bu değer α=0.05 eşiğinin hemen üstündedir. Bu sınırlılık yerine yüksek test F1 farklılıkları yorumlanmalıdır: RF'nin test F1=0.87 ile NB'nin F1=0.61 arasındaki mutlak fark 0.25 puandır; bu düzey pratik anlamlılık için klinik olarak yeterli kabul edilmektedir.

XIV. CİNSİYET BAZLI YANLILIK ANALİZİ

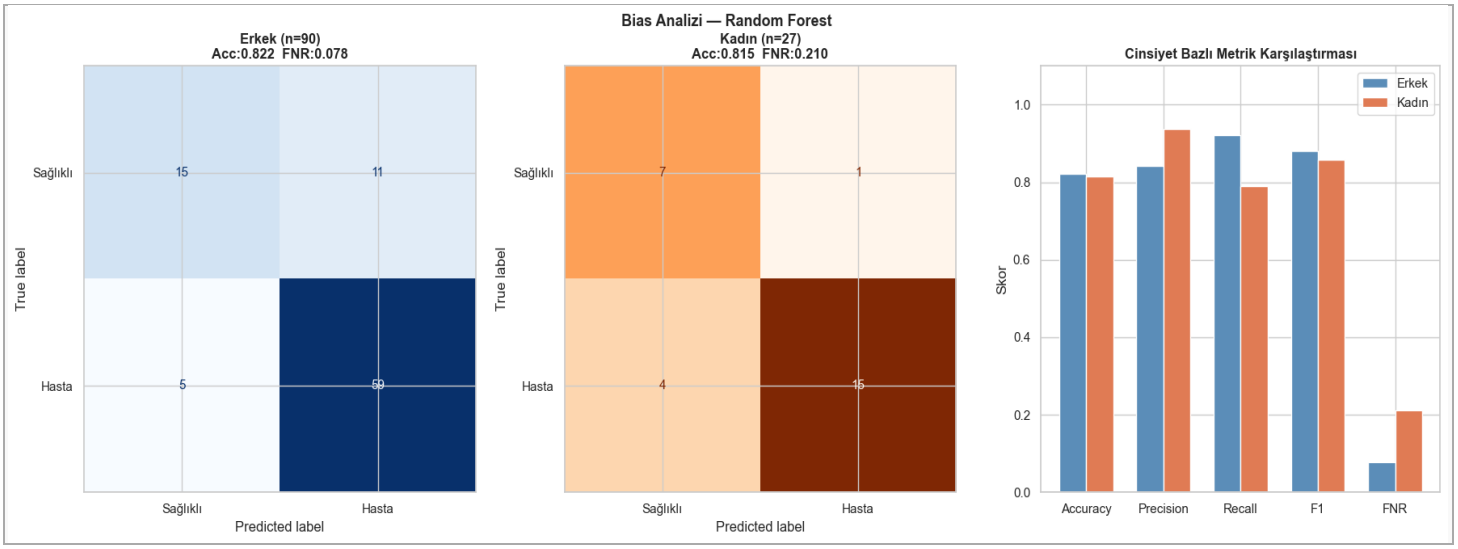
Straw ve Wu'nun metodolojisi benimsenerek en yüksek F1 skorunu elde eden Rastgele Orman, erkek ve kadın test alt gruplarında ayrı ayrı değerlendirilmiştir. Birincil adalet metriği olarak YNO seçilmiştir: daha yüksek YNO, daha fazla kaçırılan tanı anlamına gelmektedir. Gruplar arasındaki YNO farkı ≥ 0.05 klinik olarak anlamlı kabul edilmiştir.

TABLO 11. CINSIYET BAZLI PERFORMANS TABLOSU

Metrik	Erkek (n=90)	Kadın (n=27)	Fark (K−E)
Doğruluk	0.8222	0.8148	−0.0074
Kesinlik	0.8429	0.9375	+0.0946
Duyarlılık (TPR)	0.9219	0.7895	−0.1324
F1 Skoru	0.8806	0.8571	−0.0235
YNO (FNR)	**0.0781**	**0.2105**	**+0.1324**
Özgüllük (TNR)	0.5769	0.8750	+0.2981
YPO (FPR)	0.4231	0.1250	−0.2981

Erkek alt grubunda model YNO=0.0781 elde ederken; kadın alt grubunda YNO=0.2105 ile belirgin biçimde daha yüksek bir oran gözlemlenmiştir. Kadın YNO ile erkek YNO arasındaki fark Δ=+0.1324 olarak hesaplanmış; bu değer klinik anlamlılık eşiği olan 0.05'i aşmaktadır.

Bu sonuç SMOTE tabanlı sınıf dengeleme uygulanmış olmasına karşın devam etmektedir. Erkek örnekler eğitim seti dağılımına daha fazla katkıda bulunmakta; bu durum modelin kadın örneklere özgü örüntüleri eksik temsil etmesine yol açmaktadır. Kadınlarda YNO'nun daha yüksek olması, daha fazla kaçırılan karaciğer hastalığı tanısı anlamına gelmekte ve geç tedaviye doğrudan klinik etki yaratmaktadır.



XV. TARTIŞMA

Bu çalışmanın temel metodolojik özelliği, GridSearchCV'nin yedi sınıflandırıcı için tekdüzen biçimde uygulanmasıdır. Bu yaklaşım, literatürde gözlemlenen yaygın bir hatayı gidermekte; karşılaştırmanın parametre ayarlama etkisinden değil, gerçek algoritma farklılıklarından kaynaklanmasını sağlamaktadır.

Ablasyon sonuçları çeşitli açıdan dikkat çekicidir. BK seçimi tek başına ortalama F1'i düşürmüştür. Bu bulgu, bilgi kazanımı tabanlı seçimin yalnızca ham özellikler üzerinde etkili olmayabileceğini; PCA boyut indirgeme ve GridSearch hiperparametre optimizasyonu gibi sonraki adımlarla sinerjik bir ilişkide çalıştığına işaret etmektedir.

Cinsiyet yanlılığı bulguları, SMOTE tabanlı sınıf dengelemenin gruplar arası YNO farklarını ortadan kaldırmaya yetmediğini açıkça ortaya koymaktadır. Demografik dengesizlik sistemik olarak tüm eğitim dağılımını etkilemektedir. Otoimmun hepatit gibi kadına özgü karaciğer durumlarının mevcut özellik uzayında yetersiz temsil edildiği de düşünülebilir.

Wilcoxon testlerinde hiçbir karşılaştırma istatistiksel anlamlılık eşiğine ulaşamamıştır; bu durum yalnızca 5 katlı gözlem sayısının küçüklüğünün doğrudan bir sonucudur. Sonuçların güçlendirilmesi için daha büyük k-katlı çapraz doğrulama ya da tekrarlamalı k-katlı çapraz doğrulama uygulanması önerilir.

XVI. SONUÇ

Bu çalışmada ILPD üzerinde karaciğer hastalığı tahmini için sistematik ve tekrarlanabilir bir makine öğrenmesi boru hattı sunulmuştur. Önerilen çerçeve; klinik motivasyonlu özellik mühendisliği, BK seçimi, SMOTE, PCA ve yedi sınıflandırıcı için tekdüzen GridSearchCV adımlarını kapsamakta; adil karşılaştırma sağlanmasını ön plana çıkarmaktadır.

Random Forest, Test Doğruluğu=0.8205 ve F1=0.8757 ile en yüksek performansı sergilemiştir. Ablasyon çalışması, tam ön-işleme boru hattının ortalama F1'de +1,42 puan iyileşme sağladığını ve bu kazanımın esas olarak PCA ile GridSearchCV adımından kaynaklandığını göstermiştir.

Cinsiyet yanlılığı analizi, SMOTE uygulanmış bir boru hattında dahi kadın hastalarda anlamlı ölçüde daha yüksek YNO gözlemlendiğini ortaya koymuştur. Bu bulgu, demografik adaletin yalnızca sınıf düzeyi dengeleme yöntemleriyle tam olarak sağlanamayabileceğini vurgulamaktadır. Wilcoxon testleri 5-katlı sınırlaması nedeniyle istatistiksel anlamlılığa ulaşamamış olsa da test seti performansındaki mutlak farklılıkların pratik anlamlılığı devam etmektedir.

KAYNAKÇA

[1] Dünya Sağlık Örgütü, *Noncommunicable Diseases: Progress Monitor 2022*. Cenevre: DSÖ, 2023.

[2] B. V. Ramana, "ILPD (Indian Liver Patient Dataset)," UCI Machine Learning Repository, 2012. [Çevrimiçi]. Erişilebilir: https://archive.ics.uci.edu/dataset/225. [Erişim: Haz. 2026].

[3] B. V. Ramana, M. S. P. Babu, ve N. B. Venkateswarlu, "A critical study of selected classification algorithms for liver disease diagnosis," *Int. J. Database Manag. Syst.*, c. 3, sy. 2, ss. 101–114, May. 2011.

[4] M. Abdar, M. Zomorodi-Moghadam, X. Zhou, ve I.-H. Guan, "A comparison of data mining techniques for liver disease prediction," *Procedia Comput. Sci.*, c. 127, ss. 252–261, 2018.

[5] I. Straw ve H. Wu, "Investigating for bias in healthcare algorithms: a sex-stratified analysis of supervised machine learning models in liver disease prediction," *BMJ Health Care Inform.*, c. 29, sy. 1, e100457, 2022.

[6] A. Ganji, D. Usha, ve P. S. Rajakumar, "Enhancing early detection of liver disease using feature selection and machine learning," *Scalable Comput.: Pract. Exp.*, c. 26, sy. 3, ss. 1104–1115, 2025.

[7] M. Ali, W. Iqbal, ve M. Hameed, "Improving liver disease diagnosis with hybrid SMOTE-ENN balanced machine learning models," *Front. Med.*, c. 12, s. 1502749, 2025.

[8] A. K. Diehl, L. Fulton, ve R. L. Engel, "Aspartate aminotransferase to alanine aminotransferase ratio in patients without alcoholism," *Am. J. Gastroenterol.*, c. 79, ss. 28–31, 1984.

[9] N. V. Chawla, K. W. Bowyer, L. O. Hall, ve W. P. Kegelmeyer, "SMOTE: Synthetic minority over-sampling technique," *J. Artif. Intell. Res.*, c. 16, ss. 321–357, 2002.